

Artículo 2: Redes bayesianas gaussianas

AUTHOR

Ana Ana Rello de Obeso, Getzemani Kinari Ríos

Tavares, Ana Carolina Torres Villegas, David Esteban

Flores Medina

Abstract

Algunos de los contaminantes del aire son el material particulado (PM₁₀) y material particulado fino (PM_{2.5}). La exposición a estos contaminantes a corto y largo plazo, puede resultar en problemas respiratorios que afectan el estado de salud de las personas. En este artículo observamos la asociación entre la exposición a partículas del aire y los biomarcadores para entender el desarrollo de problemas respiratorios. La información utilizada proviene de la encuesta ENSANUT. Con base en nuestro análisis, aceptamos la hipótesis de que los biomarcadores son indicadores relevantes para observar la correlación entre partículas dañinas a incrementar efectos adversos respiratorios.

Introducción

La vida humana depende de las interacciones entre la atmósfera y la biosfera. Las plantas proporcionan el oxígeno que respiramos, eliminan el CO₂ que exhalamos y, a través de la transpiración, proporcionan la agua que llueve. Dichas interacciones influyen en la calidad del aire que respiramos. Los contaminantes del aire también afectan la biosfera. Ozono y deposición ácida suprimen el crecimiento de las plantas, mientras los aerosoles y sus efectos indirectos en las nubes decrecen la radiación fotosintéticamente activa (PAR) total mientras incrementan la fracción difusa.

Los biomarcadores son moléculas encontradas en sangre o fluidos corporales o tejidos que muestran la funcionalidad de un organismo biológico, son usados para estudiar el nivel de exposición de partículas del aire. Aunque las exposiciones ambientales plantean un desafío para medir un biomarcador en específico, por lo que, se requiere de un grupo de biomarcadores para imitar la exposición tanto de corto como de largo plazo. Con esto, es un aspecto útil para considerar para enlazar partículas del aire a efectos de salud respiratoria.

Metodología

El objetivo central del proceso para este trabajo fue diseñar redes bayesianas condicionales gaussianas (DAGs) que representaran de manera coherente las relaciones entre exposición a contaminantes atmosféricos, biomarcadores biológicos, condiciones socioeconómicas y enfermedades respiratorias en población mexicana, utilizando como fuentes los microdatos de ENSANUT 2022 y un archivo de calidad del aire de 2025.

Integración y preparación de fuentes de datos

En este trabajo comenzamos cargando tres bases de datos distintas. Las dos primeras provenían de la ENSANUT 2022, una con información de muestras biológicas y otra con datos sociodemográficos de las personas encuestadas. La tercera base contenía información de la calidad del aire en 2025, reportada por la SEMARNAT. La idea central fue integrar estas fuentes para construir un solo conjunto de datos que permitiera relacionar los niveles de contaminantes con variables de salud. Primero, se hizo una limpieza básica: se eliminaron registros duplicados en las bases de ENSANUT para quedarnos con una observación única por individuo. Luego, esas dos bases se unieron usando como llave el identificador de la persona, logrando así una base más completa que combinaba salud y características sociodemográficas. Después, se trabajó con la base de calidad del aire. De entre todas las fuentes posibles, se seleccionaron únicamente las fuentes fijas, ya que son las que reportan de manera más consistente y con menos valores faltantes. Como los nombres de las entidades federativas venían escritos de formas diferentes entre ENSANUT y SEMARNAT (con números, acentos o minúsculas), se estandarizaron: se eliminaron prefijos numéricos, se quitaron acentos y todo se transformó a mayúsculas. Con ello, se logró que los nombres fueran comparables y se pudiera realizar el cruce de información. Una vez listos los nombres, se calcularon los promedios de contaminantes por entidad federativa en la base de calidad del aire. Esto permitió asignar a cada persona encuestada en ENSANUT los valores medios de contaminación correspondientes a su estado de residencia. Aunque los datos de contaminantes eran de 2025, se asumió —como lo indica la consigna— que representaban bien las condiciones a las que estuvieron expuestos los individuos en 2022. Con esa integración de datos lista, se seleccionaron variables específicas para armar la red bayesiana: por un lado, contaminantes como CO, NOx, SO₂, COV, NH₃, PM_{2.5} y PM₁₀; por otro, indicadores de salud como biomarcadores (creatinina, ácido úrico, ferritina, vitamina D) y la presencia de enfermedades, además de variables relacionadas con COVID-19 y sus secuelas. Estas variables se renombraron con etiquetas más cortas y manejables para facilitar el trabajo posterior. Luego se definió explícitamente una estructura causal (DAG), es decir, un esquema de flechas que indicaba cómo se supone que se relacionan las variables. Por ejemplo, el municipio dependía de la entidad, los contaminantes dependían del municipio, el estado de salud de una persona dependía de la combinación de contaminantes y del estrato socioeconómico, y las secuelas de COVID dependían de haber tenido la enfermedad. Esta red se plasmó en código y se visualizó en un diagrama para confirmar la coherencia de la estructura. Posteriormente, fue necesario preparar los datos para que se ajustaran a este tipo de modelo: se transformaron variables categóricas en factores, se convirtieron a números las binarias (0 y 1), y se revisaron codificaciones especiales como el valor "98" en la variable de COVID. Con esto, los datos quedaron en un formato compatible con una red bayesiana gaussiana, donde las relaciones se modelan como distribuciones normales condicionadas. Finalmente, la red se ajustó a los datos usando el paquete bnlearn, lo que permitió estimar los parámetros asociados a cada nodo (medias, varianzas o regresiones, según el caso). Para evaluar qué tan bien se ajustaba el modelo, se calcularon criterios de información (BIC y AIC). Aunque en el código se hace a través de modelos nulos individuales, el objetivo fue contar con métricas comparativas que indicaran la calidad y parsimonia de la red propuesta. En conjunto, todo este proceso transformó tres fuentes de datos independientes en un solo modelo probabilístico capaz de capturar relaciones causales entre contaminación ambiental y salud. La red obtenida no sólo organiza el conocimiento, sino que también permite responder consultas específicas, como estimar la probabilidad de enfermar dado cierto nivel de contaminantes, o analizar el efecto esperado de la exposición en distintos biomarcadores.

Entrevistas y criterios de selección

El proceso de selección de variables y de diseño causal se apoyó en entrevistas a diferentes perfiles expertos en los temas que tratamos. Desde la perspectiva de procesos atmosféricos, se recomendó priorizar contaminantes con relevancia en emisiones urbanas e industriales y con correlaciones conocidas, en particular las asociaciones entre PM2.5 y PM10, así como entre monóxido de carbono y óxidos de nitrógeno, además de distinguir claramente entre concentraciones ambientales medidas por estaciones y la exposición personal modulada por vivienda, movilidad y ocupación. Desde la perspectiva biomédica, se trazaron las rutas biológicas plausibles por las cuales la contaminación particulada y gaseosa podría elevar marcadores inflamatorios como la proteína C reactiva y la ferritina, afectar el estado vitamínico y, en conjunto, relacionarse con síntomas y diagnósticos respiratorios; asimismo, se sugirió mantener separado el bloque de COVID por su papel agravante más que causal directo.

A partir de estas orientaciones se consolidó un núcleo de variables de exposición, biomarcadores y salud respiratoria con dos variables de estructura territorial, estrato y región, para capturar diferencias contextuales. La evidencia cualitativa también motivó la decisión de no sobrecargar el modelo principal con múltiples covariables sociodemográficas poco informativas en esta fase, a fin de preservar parsimonia y evitar colinealidad excesiva, decisión que se acompaña de un análisis de sensibilidad y de una discusión explícita de limitaciones.

DAGs propuestos

Se propusieron cuatro estructuras causales complementarias. La primera es un modelo parsimonioso que toma el estrato de residencia como determinante exógeno de la variación en los contaminantes; las diferencias entre contextos rural, urbano y metropolitano se propagan hacia PM2.5, PM10, compuestos orgánicos volátiles y monóxido de carbono, y estos a su vez se vinculan con la probabilidad de presentar enfermedad respiratoria. Esta especificación sirve como línea base de complejidad reducida para contrastar con modelos más ricos (poner dag aqui).

La segunda estructura mantiene la simplicidad del grafo pero sustituye el estrato por una regionalización del país en macrogrupos con perfiles de industrialización distintos; cada grupo modula los niveles de CO, NOx, NH3, PM10 y PM2.5, y por esa vía su relación con la enfermedad. Su función es capturar gradientes territoriales amplios sin incorporar todavía la jerarquía geográfica completa (poner aqui la otra dag)


La tercera estructura extiende el marco anterior e introduce explícitamente la jerarquía geográfica de entidad y municipio, junto con el estrato, como origen de la variación espacial en la mezcla de contaminantes. Todos estos determinantes confluyen en un estado de “enfermo”, del cual se desprende la condición de “enfermedad”, y aguas abajo se sitúan los biomarcadores como indicadores biológicos del proceso. En paralelo se mantiene un bloque de COVID con variables relacionadas para representar antecedentes o secuelas que pueden agravar el cuadro sin constituir una vía causal directa de la contaminación (poner aqui la tercera dag)

La cuarta estructura comparte el fundamento contextual del modelo anterior pero cambia los desenlaces terminales por síntomas respiratorios, como tos, disnea, sibilancias, dolor de garganta e


infección respiratoria aguda, y conserva el nodo de búsqueda de atención médica, que captura el componente conductual que influye en la detección y reporte de síntomas. Los biomarcadores permanecen como indicadores del estado inflamatorio y metabólico, conectados con dichos síntomas. (cuarta dag aqui)

Las cuatro redes se ajustarán sobre la misma muestra y bajo un preprocesamiento común para garantizar comparabilidad. La selección del grafo operativo para los análisis principales se realizará con criterios de parsimonia y ajuste basados en puntuaciones de información como BIC y AIC, complementados con plausibilidad causal sustentada en la literatura y en las entrevistas; la comparación cuantitativa y la interpretación de las dependencias clave se presentarán en la sección de aplicación.


DAG 1




DAG 2 (No usada)



DAG 3





Creación de DAGs y criterios de evaluación

La construcción de las redes, en una primera etapa, se definieron los nodos y su tipo (contaminantes y biomarcadores continuos; desenlaces y variables de contexto categóricas) y se fijaron las aristas obligatorias y prohibidas de acuerdo con la justificación sustantiva. Con ese esqueleto se ejecutó una búsqueda de estructura mediante un algoritmo de ascenso de colina con puntuación BIC gaussiana sobre el subgrafo continuo, manteniendo constantes la semilla y el conjunto de datos para garantizar comparabilidad. Posteriormente se ajustaron los parámetros por máxima verosimilitud y se exportaron las figuras. Las redes extendidas (diagnósticos y síntomas) se obtuvieron replicando el mismo flujo de reutilizar el conjunto de nodos, imponer las restricciones estructurales específicas (jerarquía estado-municipio, bloque de COVID y búsqueda de atención), ejecutar la búsqueda y comparar el BIC del subgrafo continuo con el de las variantes basales (estrato y regiones). Debido a las restricciones del modelo condicional gaussiano, las variables categóricas no contribuyen al puntaje reportado.

Aplicación

Aquí implementamos la metodología sobre el conjunto unificado de ENSANUT–calidad del aire, tras la depuración y estandarización descritas en Metodología. Se ajustaron las estructuras propuestas bajo el mismo preprocesamiento y con búsqueda de estructura y ajuste paramétrico consistentes. Para garantizar comparabilidad, la evaluación cuantitativa se centró en la componente continua común (contaminantes y biomarcadores), dejando la incorporación plena de variables categóricas como trabajo en curso. A continuación se presenta la comparación de desempeño entre grafos.

Comparación de estructuras: BIC y AIC

Lo que se hizo fue primero definir **modelos lineales nulos** (es decir, modelos con intercepto únicamente, sin predictores) para cada una de las variables numéricas seleccionadas en la DAG.

Por ejemplo, un modelo nulo para el contaminante **CO** fue:

$$CO \sim 1$$

Esto significa que el modelo simplemente estima la **media de CO** sin explicar la variación con otras variables.

El mismo procedimiento se aplicó a **NOx, SO₂, COV, NH₃, PM_{2.5}, PM₁₀, estrato, entidad y municipio**. Cada uno de estos modelos se ajustó de manera independiente.

Una vez ajustados, se extrajo el valor del **AIC** y del **BIC** para cada modelo.

Luego, todos esos valores se **sumaron** y se aplicó un ajuste de escala (multiplicación por $-1/2$), con lo cual se obtuvo un **AIC total** y un **BIC total** para la red propuesta.

Este procedimiento no da el AIC/BIC de la red en su conjunto de forma exacta, sino una aproximación construida a partir de los modelos parciales. Sin embargo, sirve como un **criterio comparativo** para evaluar la calidad del ajuste.

Criterios de información: fórmulas

El **AIC** y el **BIC** se calculan a partir de la log-verosimilitud del modelo.

1. **AIC** (Akaike Information Criterion):

$$AIC = 2k - 2 \ln(\hat{L})$$

donde:

- k = número de parámetros estimados en el modelo,
- $\hat{L}$ = valor máximo de la función de verosimilitud.

La idea es penalizar la complejidad: un modelo con muchos parámetros tendrá un AIC mayor, a menos que la mejora en la verosimilitud lo justifique.

2. **BIC** (Bayesian Information Criterion):

$$BIC = k \ln(n) - 2 \ln(\hat{L})$$

donde:

- n = tamaño de la muestra,
- k = número de parámetros estimados,
- $\hat{L}$ = verosimilitud máxima.

Aquí la penalización es más fuerte que en el AIC, porque depende del tamaño de la muestra ($\ln(n)$).

Los BICs y AICs de las DAGs analizadas fueron los siguientes:

- 1: -392087.8, -400519.7
- 3: -195292.9, -195253.3
- 4: -329987.1, -329927.2

Siendo la mejor estructura la segunda DAG.

Modelos no paramétricos

En nuestro trabajo, el cálculo de **AIC** y **BIC** se hizo inicialmente con modelos lineales simples (únicamente con intercepto), lo cual entrega una primera aproximación de ajuste.

Sin embargo, estos modelos imponen la restricción de **linealidad**: asumen que el efecto de un contaminante sobre la salud es proporcional y constante, lo cual en la práctica rara vez ocurre. Factores ambientales y biológicos suelen tener **relaciones no lineales** (por ejemplo, un contaminante puede no afectar a bajas concentraciones pero sí a partir de cierto umbral).

Matemáticamente, el **AIC** y el **BIC** penalizan la complejidad del modelo de la siguiente manera:

$$AIC = 2k - 2 \ln(\hat{L})$$

$$BIC = k \ln(n) - 2 \ln(\hat{L})$$

donde k es el número de parámetros y $\hat{L}$ es la verosimilitud máxima.

En modelos no paramétricos, el número de parámetros efectivos (k) aumenta porque se añaden **grados de libertad** para representar curvas. No obstante, al mejorar la verosimilitud (es decir, al describir mejor la realidad de los datos), el término $-2 \ln(\hat{L})$ disminuye.

Si la ganancia en verosimilitud compensa el incremento de complejidad, el AIC y el BIC resultan **más bajos**, lo que indica un modelo mejor. En la práctica, esto significa que, al usar **modelos no paramétricos** en nuestra DAG, se logra capturar con mayor fidelidad los patrones entre contaminantes y salud.

Por ejemplo, la relación entre partículas **PM_{2.5}** y enfermedades respiratorias puede no ser lineal, sino mostrar un **crecimiento acelerado** a partir de cierto nivel.

Un modelo lineal lo subestimaría, pero un modelo no paramétrico lo detectaría, reduciendo así los criterios de información.

Link de github

<https://github.com/anaanarello/incertidumbre.git>

Referencias

- Akaike, H. (1974). A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 19(6), 716–723. <https://doi.org/10.1109/TAC.1974.1100705>
- Schwarz, G. (1978). Estimating the dimension of a model. *The Annals of Statistics*, 6(2), 461–464. <https://doi.org/10.1214/aos/1176344136>
- Hastie, T., & Tibshirani, R. (1990). *Generalized Additive Models*. London: Chapman and Hall/CRC.

- Suhaimi, N. F., & Jalaludin, J. (2015). Biomarker as a research tool in linking exposure to air particles and respiratory health. *BioMed Research International*, 2015, 1–10.
<https://doi.org/10.1155/2015/962853>
- Atmosphere-biosphere interactions – Atmospheric chemistry and global change research group. (n.d.). Recuperado de: <https://acgc.eoas.fsu.edu/research/atmosphere-biosphere-interactions/>
- National Cancer Institute. (n.d.). *Definition of biomarker*. NCI Dictionary of Cancer Terms. Recuperado de: <https://www.cancer.gov/publications/dictionaries/cancer-terms/def/biomarker>